Montisci Matteo, Osimani Davide, Scibilia Tommaso, Zero Edoardo

RELAZIONE SERIE TEMPORALI

ARRIVI E PARTENZE TOTALI ALL'ESTERO IN AUSTRALIA

Introduzione e descrizione del dataset

I dati analizzati in questa relazione provengono dal sito australiano "Australian Bureau of Statistics" e riguardano il numero di arrivi e di partenze in Australia e dall'Australia nel periodo compreso tra marzo 2014 e aprile 2024. In particolare, i dati indicano il numero di attraversamenti delle frontiere australiane, sono espressi in milioni ed approssimati alle decine di migliaia.

I valori osservati sono stati suddivisi in due serie storiche differenti, quella degli arrivi e quella delle partenze. Le serie sono costituite ciascuna da 122 osservazioni mensili, che indicano il numero totale di entrate ed uscite dal paese in ciascun mese.

Lo scopo di questa relazione è quello di studiare con il Metodo di Box-Jenkins le due serie temporali fino a dicembre 2019 per osservare eventuali relazioni fra di esse e per predire come sarebbe stato l'andamento dei dati negli anni successivi se non si fosse verificata la pandemia di Covid. Successivamente, attraverso i risultati ottenuti e alle osservazioni rilevate in seguito al lockdown si cerca di capire se i numeri mensili degli attraversamenti delle frontiere australiane stanno tornando come quelli pre-covid.

Analisi descrittiva e grafica delle serie temporali

Sono state quindi considerate le prime 70 osservazioni mensili delle due variabili, creando così le due serie temporali sugli arrivi e le partenze in Australia prima del covid, da marzo 2014 a dicembre 2019. I timeplot delle due serie sono i seguenti.

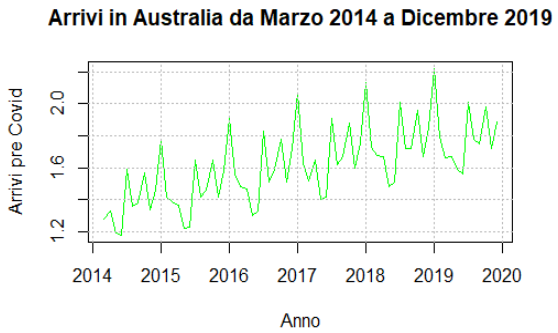

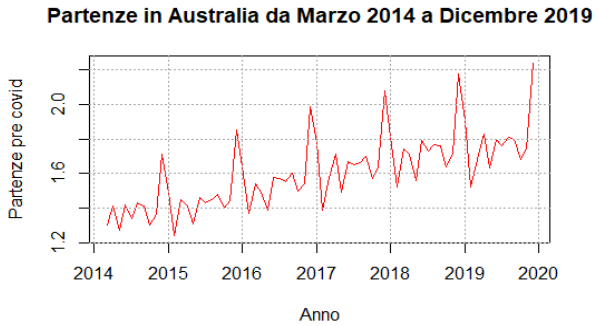

Osservando i grafici è possibile notare che entrambe le serie hanno una leggera tendenza crescente, conclusione che viene confermata anche esaminando i primi e gli ultimi valori assunti dalle due serie, le mediane e i primi e i terzi quartili.

```
> head(Arrivi_pre)
      Mar  Apr  May  Jun  Jul  Aug
2014 1.28 1.33 1.19 1.18 1.59 1.36
```

```
> tail(Arrivi_pre)
      Jul  Aug  Sep  Oct  Nov  Dec
2019 2.01 1.78 1.75 1.98 1.72 1.89
```

```
> head(Partenze_pre)
      Mar  Apr  May  Jun  Jul  Aug
2014 1.30 1.41 1.27 1.42 1.34 1.43
```

```
> tail(Partenze_pre)
      Jul  Aug  Sep  Oct  Nov  Dec
2019 1.76 1.81 1.80 1.68 1.74 2.24
```

```
> summary(Arrivi_pre)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1.180   1.430   1.610   1.616   1.758   2.220
```

```
> summary(Partenze_pre)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1.240   1.442   1.580   1.605   1.738   2.240
```

Oltre al trend crescente, tutte e due le serie presentano una certa stagionalità, con picchi positivi nel mese di gennaio e negativi nei mesi di maggio e giugno per la serie degli arrivi e con picchi positivi nel mese di dicembre e negativi nel mese di febbraio per la serie delle partenze.

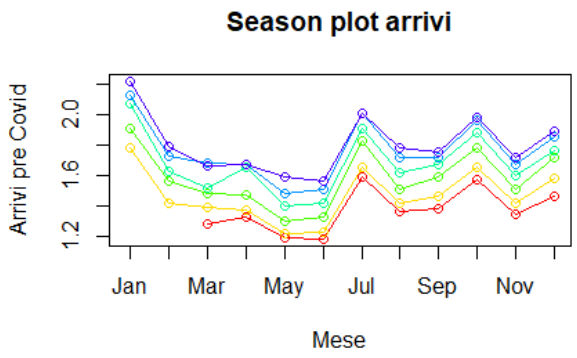

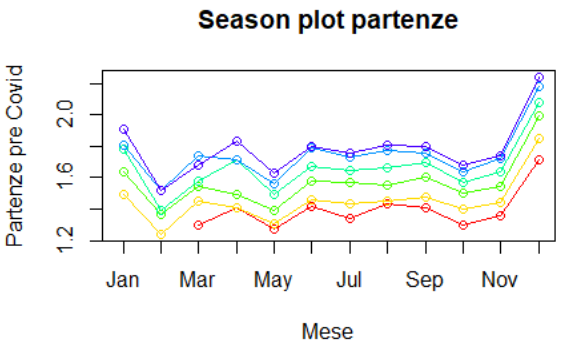

Osservando i lag plot si può affermare che la stagionalità è per entrambe annuale (correlazione lineare nei dodicesimi lag) e che le serie, soprattutto quella delle partenze, non sono stazionarie in varianza (leggera forma ad imbuto dei valori osservati nei primi 11 lag).

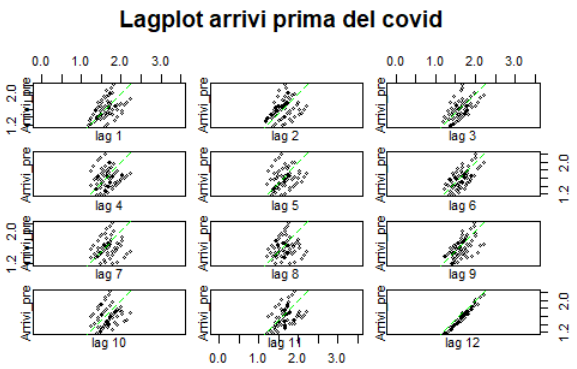

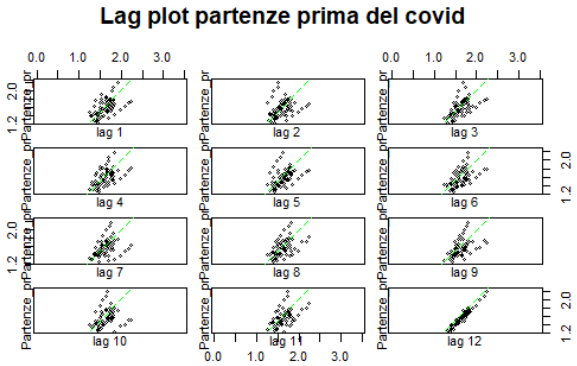

Trasformazione delle Serie Temporali in Serie Stazionarie

A questo punto, dopo aver individuato il trend attraverso il time plot e l'eterogeneità di varianza osservando il lag plot, per rendere le serie stazionarie in media e i in varianza sono state applicate le seguenti trasformazioni:

- **Trasformazione Box-Cox**: Per stabilizzare la varianza
- **Differenziazione**: Per rimuovere la tendenza, applicando l'operatore delle differenze prime alle serie trasformate.

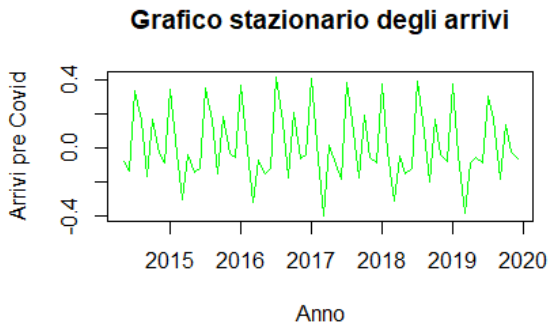

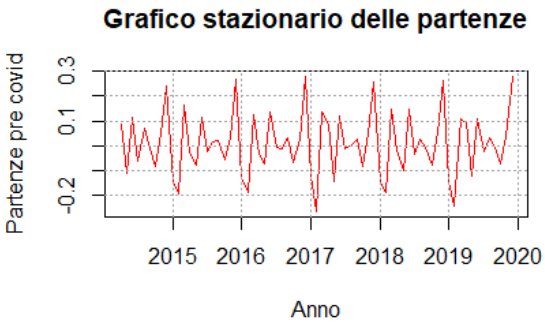

Infine, per rimuovere l'effetto stagionale annuale è stato applicato alle serie l'operatore delle differenze dodicesime.
È possibile valutare l'efficacia della trasformazione osservando i time plot e i lag plot dodicesimi delle due serie.

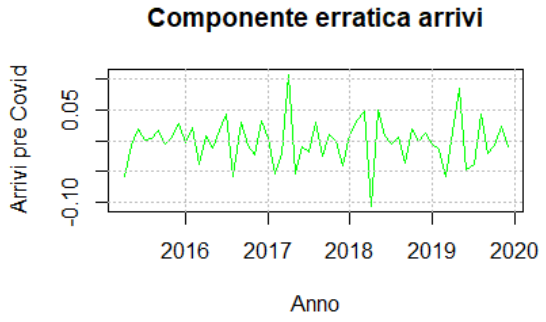

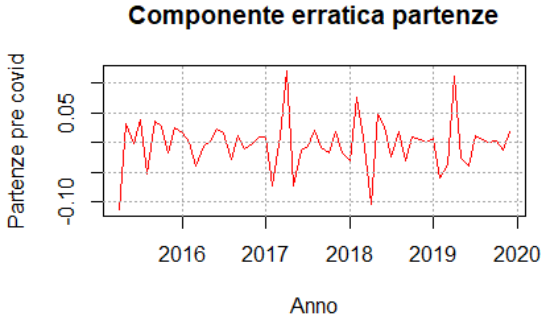

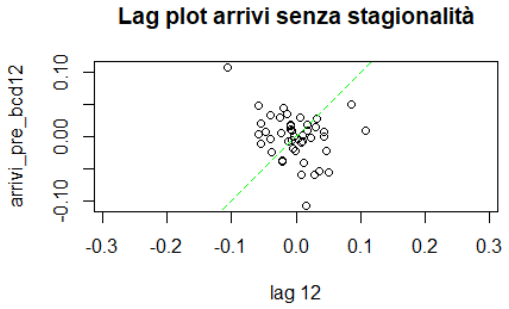

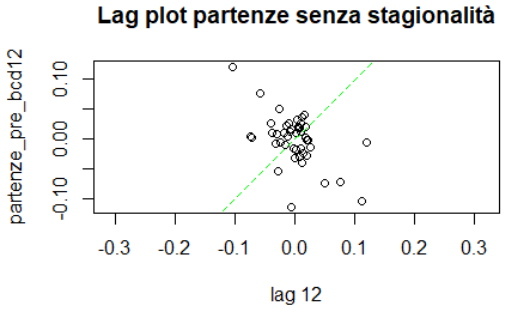

L'andamento delle serie nei time plot sembra essere aleatorio, senza stagionalità.
Nei lag plot dodicesimi sono presenti nuvole di punti, non c'è più correlazione lineare.

Analisi delle Funzioni di Autocorrelazione e Autocorrelazione Parziale

Sono state calcolate le funzioni di autocorrelazione (ACF) e di autocorrelazione parziale (PACF) delle serie differenziate degli arrivi e delle partenze.

Dall'analisi di ACF e PACF della serie degli arrivi:

- L'ACF mostra un taglio netto dopo il primo lag: questo suggerisce che la serie originale potrebbe avere un processo MA (1). Tuttavia, successivamente, presenta un effetto decrescente e il secondo e il terzo lag non si trovano ancora dentro le bande tratteggiate. La funzione, quindi, potrebbe anche suggerire un modello MA (2) o MA (3).
- La PACF, invece, non mostra un taglio netto e i valori sembrano variare in modo casuale senza una decrescita: questo indica che la serie originale non presenta una componente AR significativa.

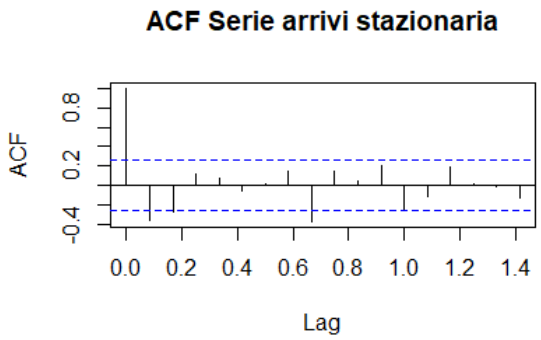

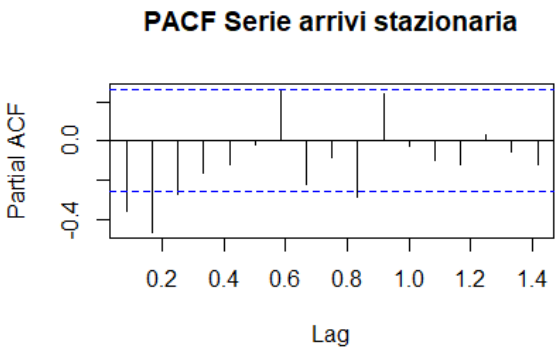

Dall'analisi di ACF e PACF della serie delle partenze:

- L'ACF, come nel caso degli arrivi, mostra un taglio netto dopo il primo lag, suggerendo che la serie originale potrebbe avere una componente MA di ordine 1.
- Per la PACF vale il discorso fatto in precedenza per la funzione di autocorrelazione parziale degli arrivi: non sembra che la serie originale delle partenze presenti una componente AR significativa.

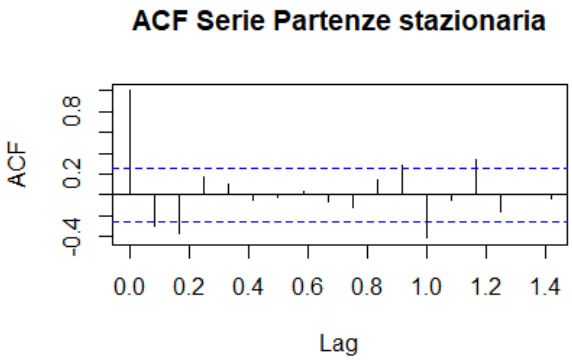

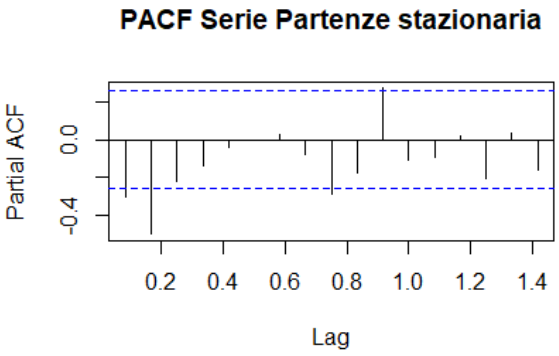

Stima del modello

Attraverso le conclusioni tratte dall'analisi delle funzioni di autocorrelazione e autocorrelazione parziale e grazie alla funzione `auto.arima` di R studio, è possibile identificare il processo generatore delle serie storiche stimando i suoi parametri.

Basandosi sulle osservazioni precedenti è possibile identificare il modello ARIMA(p,d,q) più adeguato, che risulta lo stesso per entrambe le serie:

- p = 0 (dall'analisi della PACF)
- d = 1 (numero di differenziazioni per rendere la serie stazionaria)
- q = 1 (dall'analisi della ACF)

Gli esiti della funzione `auto.arima` per identificare automaticamente i migliori parametri per il modello SARIMA generatore delle due serie sono i seguenti:

- Per la serie degli arrivi i modelli migliori, in ordine di bontà di adattamento, risultano essere ARIMA(0,1,1)(0,1,1)[12] e ARIMA(0,1,2)(0,1,1)[12]
- Mentre per la serie delle partenze sono ARIMA(0,1,1)(0,1,1)[12] e ARIMA(0,1,1)(1,1,0)[12]

Tuttavia, la bontà di adattamento dei modelli ARIMA(0,1,2)(0,1,1)[12] e ARIMA(0,1,1)(1,1,0)[12] ai dati è elevata per entrambe le serie.

I risultati ottenuti confermano quanto detto prima riguardo all'analisi dell'ACF e della PACF, oltre a suggerire nette relazioni tra i dati delle due serie temporali.

Scelta e verifica del modello

Sono stati eseguiti i controlli diagnostici per verificare l'adeguatezza del modello ARIMA(0,1,1)(0,1,1)[12] per entrambe le serie.
Successivamente sono stati confrontati con i controlli di un altro modello, con bontà di adattamento minore ai dati ma con parametri più semplici, per vedere se è possibile stimare il processo generatore delle due serie in modo "meno costoso" ma senza perdere troppe informazioni.

I residui del modello sono la differenza tra i valori osservati e i valori predetti dal modello. Idealmente, i residui dovrebbero comportarsi come rumore bianco, ovvero essere non correlati e avere media zero.

Analizzando le funzioni di autocorrelazione e di autocorrelazione parziale dei residui del modello ARIMA(0,1,1)(0,1,1)[12] è possibile osservare che presentano valori non significativi a quasi tutti i lag: questo significa che non ci dovrebbe essere correlazione elevata e che non ci sono pattern auto regressivi e a media mobile non modellati rimasti nei residui.

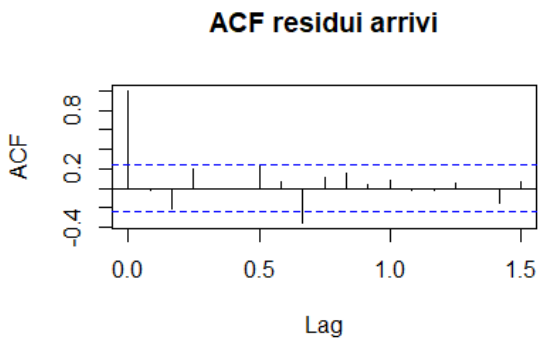

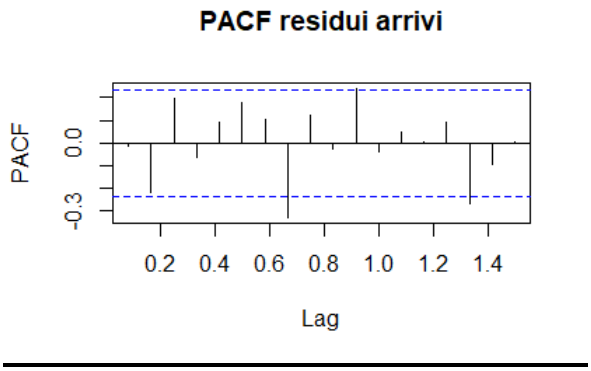

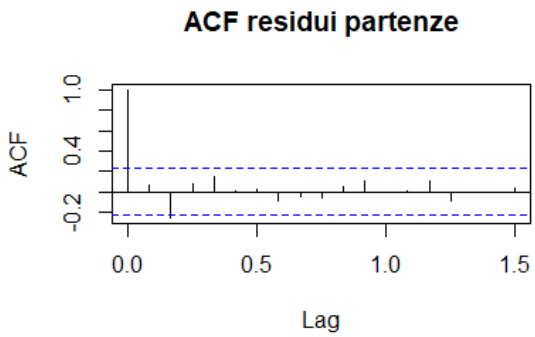

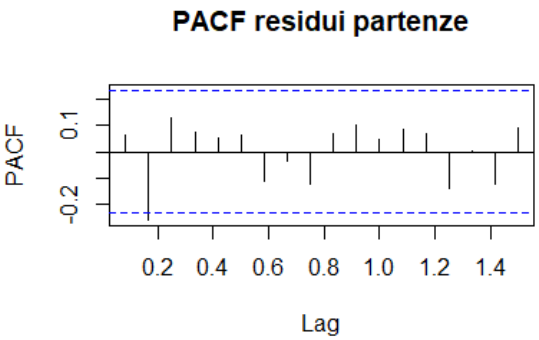

I timeplot dei residui, inoltre, mostrano un comportamento casuale, mentre i lag plot una nuvola di punti, entrambi senza alcun pattern evidente. Tutte informazioni che indicano che il modello cattura bene la struttura della serie.

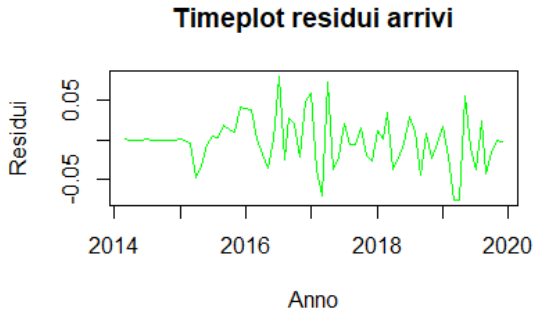

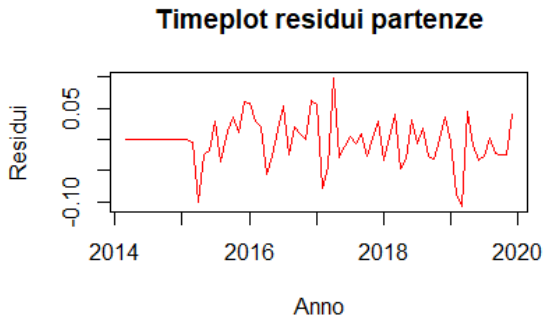

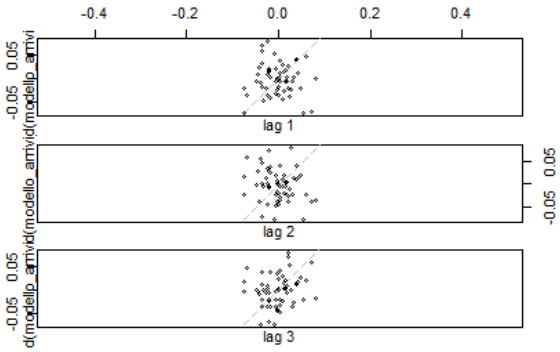

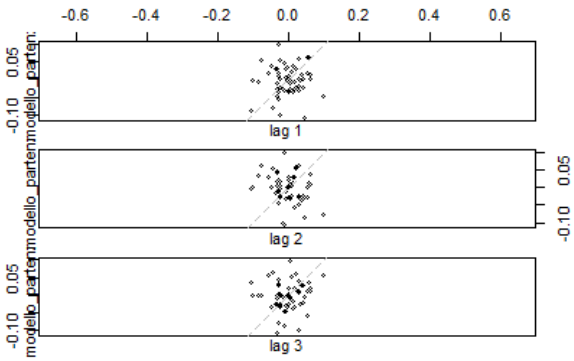

È stato considerato ora il modello ARIMA(0,1,1)(0,1,0)[12], più semplice a livello di parametri ma con bontà di adattamento minore ai dati delle due serie. Tuttavia, osservando i timeplot dei residui del modello è possibile osservare dei picchi decisamente più marcati e una leggera decrescenza con l'aumentare del tempo: questo potrebbe indicare che il modello non ha modellato adeguatamente tutte le dinamiche della serie temporale.

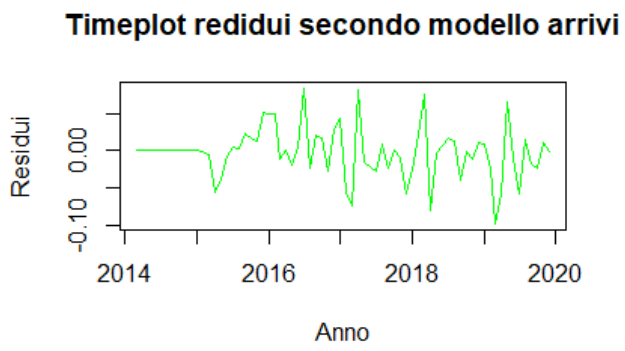

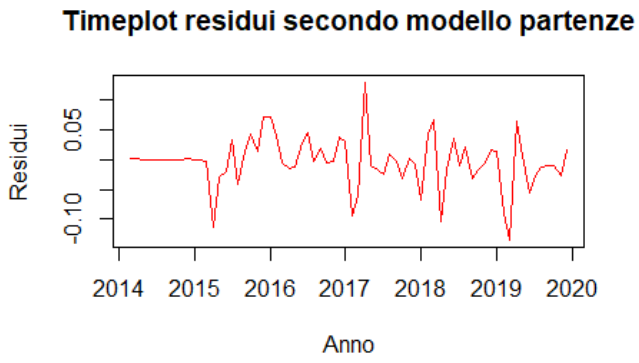

In conclusione, il modello **ARIMA(0,1,1)(0,1,1)[12]** sembra essere il migliore per approssimare i dati delle due serie temporali, poiché i suoi residui si comportano più come rumore bianco rispetto a quelli del Modello 2. Inoltre, non essendo un modello con parametri troppo "costosi" da stimare, non ci sono motivi rilevanti per scegliere il secondo modello rispetto al primo.

Predizione attraverso il modello scelto.

A questo punto, è possibile utilizzare il modello scelto per predire quale sarebbe stato il numero di entrate ed uscite dalle frontiere australiane fino al 2024 se non ci fosse stato il lockdown e confrontare le predizioni con il reale andamento delle due serie.

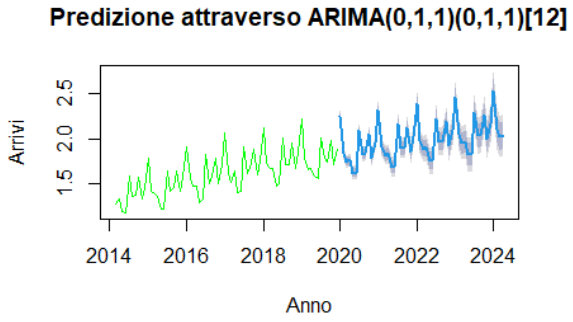

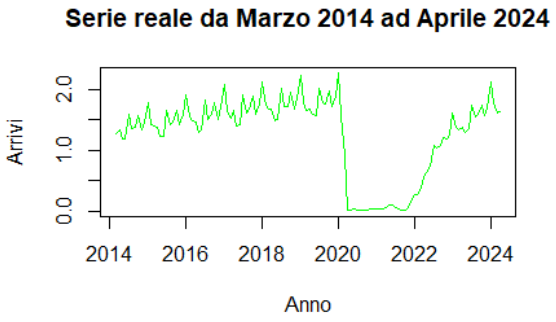

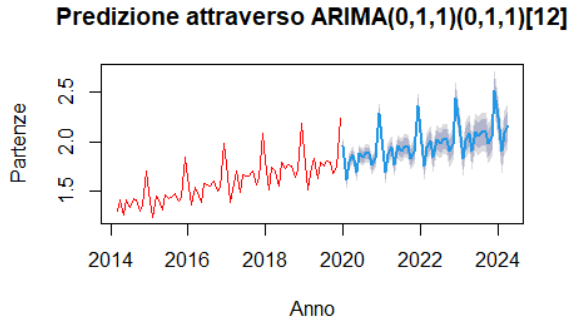

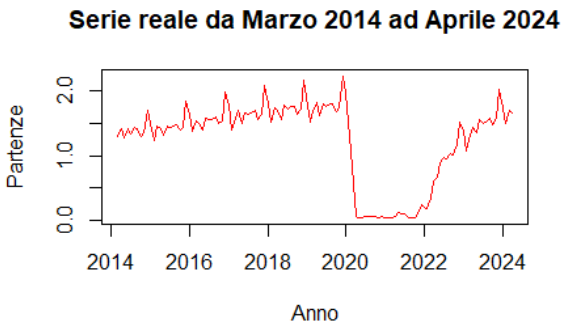

Per entrambe le serie le predizioni indicano una continuazione del trend crescente con fluttuazione stagionale uguale a quella degli anni prima della pandemia. Andamento molto differente rispetto alla decrescita improvvisa dovuta dal covid nel 2020 e alla successiva crescita esponenziale con minore stagionalità dal 2022 in poi.

Relazioni tra arrivi e partenze

Sono già state individuate nette relazioni tra la serie temporale degli arrivi e quella delle partenze negli anni prima della pandemia.
Entrambe le serie hanno trend crescente, stagionalità annuale e sono generate dallo stesso modello.
Osservando il grafico si può individuare ancora meglio la somiglianza tra le due serie storiche.

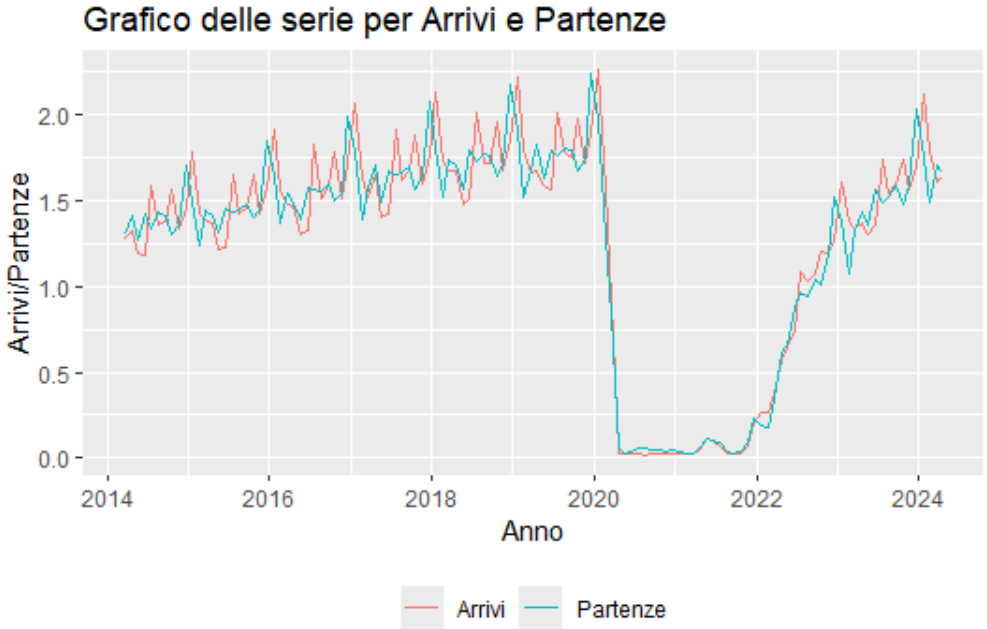

Oltre a confermare quanto detto prima sull'andamento molto simile tra arrivi e partenze, il grafico ci dà anche informazioni sui valori assunti dalle due serie, anche in questo caso molto simili poiché i due timeplot sono quasi sovrapposti. Il numero di persone che escono mensilmente dall'Australia è quindi conforme col numero di persone che entrano.
L'unica differenza evidente tra le due serie è come vengono assunti i valori durante l'anno.
Il numero di persone che esce dalle frontiere, infatti, ha un unico grosso picco positivo nel mese di dicembre, ovvero il periodo in cui iniziano le vacanze estive in Australia, mentre assume il valore minore a febbraio, mese in cui inizia l'anno scolastico.
La serie degli arrivi, invece, ha diversi picchi positivi, probabilmente nei periodi in cui gli altri stati del mondo vanno in vacanza, assume valore massimo nel mese di gennaio, durante l'estate australiana, e valori minimi a maggio e giugno, ovvero i mesi più freddi e piovosi dell'anno.
È importante anche specificare che il numero di partenze mensili è quasi pari a quello degli arrivi poiché, probabilmente, un gran numero di turisti entra ed esce dal paese nello stesso mese.
Il grafico, inoltre, ci mostra anche una certa somiglianza tra le due serie nel periodo dopo la pandemia.

Si sta tornando a viaggiare come prima?

Osservando i timeplot sugli arrivi e sulle partenze si può vedere che nel 2024 le serie stanno tornando a stabilizzarsi, diminuendo la crescita esponenziale degli anni precedenti e riacquisendo un andamento con picchi mensili.
Per questo motivo i dati ottenuti nei mesi del 2024 sono stati confrontati coi dati ricavati prima del covid per vedere se le persone stanno tornando a viaggiare regolarmente come prima.
I valori registrati nei primi 4 mesi dell'anno corrente sembrano essere molto simili coi primi 4 valori del 2017.
A questo punto si può estendere il confronto anche con i dati dell'anno precedente, per vedere se già dal 2023 si stesse tornando all'andamento delle serie nel periodo precedente al covid e che non fosse solo un caso degli ultimi 4 valori rilevati.

Sono stati quindi creati 2 grafici, uno sugli arrivi e uno sulle partenze, in cui vengono comparati i dati registrati nel 2016/17 con quelli ricavati nel 2023/24.

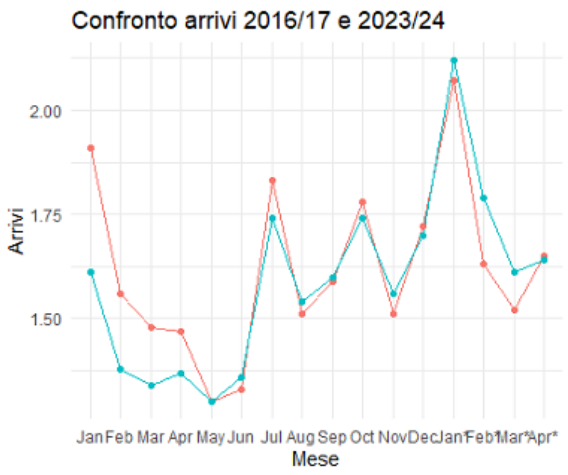

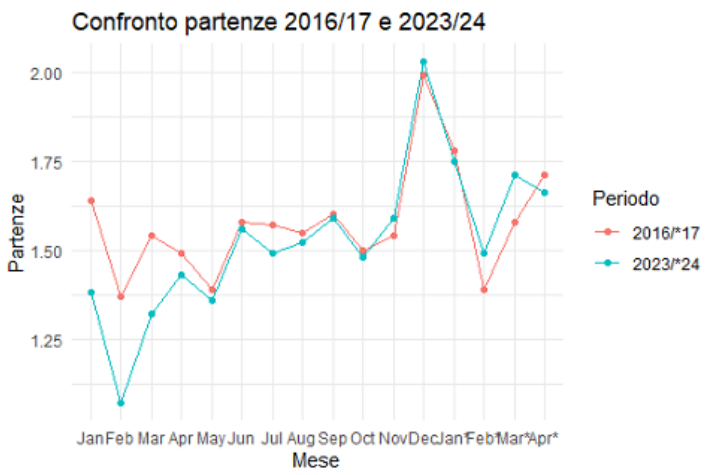

Il grafico sembra confermare quanto ipotizzato prima: il numero di persone che oltrepassano la frontiera australiana sembra essere tornato uguale a quello del periodo precedente alla pandemia. Osservando il grafico, infatti, si può notare che, sia per gli arrivi che per le partenze, nel mese di maggio i valori del 2016 e del 2023 sembra combaciare e che le due serie mantengono un andamento quasi uguale fino a gennaio dell'anno dopo. Successivamente sembra che la serie dell'anno corrente tenda ad assumere valori più alti rispetto al 2017.

Tuttavia, anche se le due serie negli ultimi anni hanno avuto una crescita più rapida rispetto al trend degli anni prima del 2020, confrontando la serie originale con la predizione fatta in precedenza si può osservare che l'andamento reale assume comunque valori più bassi rispetto a quelli che avrebbe assunto non si fosse verificata la pandemia di covid.

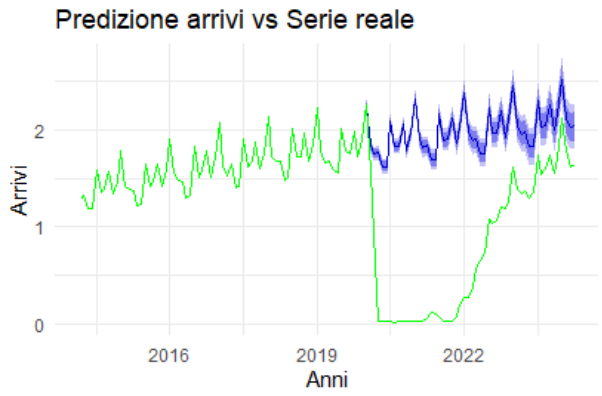

Conclusione

Si può affermare che l'andamento del numero delle persone che entrano ed escono mensilmente dall'Australia sta tornando simile a quello presente prima della pandemia.
Tuttavia, non sono ancora stati toccati i valori che si sarebbero rilevati negli ultimi mesi se non fosse arrivato il covid, ma il ritmo più elevato con cui sta crescendo la serie fa sperare ad un possibile raggiungimento di tale obbiettivo.
È importante specificare, infine, che la predizione non va mai interpretata come una verità assoluta, poiché si basa su dati storici che non possono tenere conto di eventi imprevisti o eccezionali, come il covid, che potrebbero avere un impatto significativo e stravolgere completamente la predizione.