RELAZIONE PCA : ESERCITAZIONE 5

Edoardo Zero SMID

Lo scopo di questa analisi è ridurre la dimensione dello spazio in cui si trovano i punti-unità sperimentali in modo da perdere la minor quantità di informazioni possibile sostituendo alle otto variabili di partenza un numero inferiore di nuove variabili.

Prima di procedere con lo studio della PCA, è opportuno standardizzare le variabili. Successivamente si può iniziare.

Si ottengono otto nuove componenti che sono combinazioni lineari delle variabili originali che descrivevano la percentuale di acidi grassi negli oli italiani. Le componenti ottenute presentano queste caratteristiche:

Importance of components:

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5	Comp.6	Comp.7	Comp.8
Standard deviation	1.9290956	1.3288331	1.0081446	0.89044867	0.57776956	0.49881727	0.34470293	0.0456263329
Proportion of Variance	0.4651763	0.2207247	0.1270444	0.09911235	0.04172721	0.03110233	0.01485251	0.0002602203
Cumulative Proportion	0.4651763	0.6859009	0.8129454	0.91205772	0.95378493	0.98488727	0.99973978	1.0000000000

Di queste 8 nuove componenti bisogna trovare quali rappresentano meglio le variabili originali e quindi quelle che si analizzeranno in seguito. Vedremo in seguito tre criteri che permetteranno di stabilire le componenti principali di questa PCA.

Nella tabella sopra riportata sono evidenziati i valori più importanti. In verde sono sottolineate le '*Standard deviation*' delle prime tre componenti , si può notare che tutte e tre hanno un valore superiore a uno , ciò vuol dire che la varianza sarà superiore a uno, quindi questo è un primo criterio che permette di considerare le prime tre componenti quelle principali. Dal barplot sotto riportato si possono osservare meglio i dati riguardanti il valore della varianza nelle componenti :

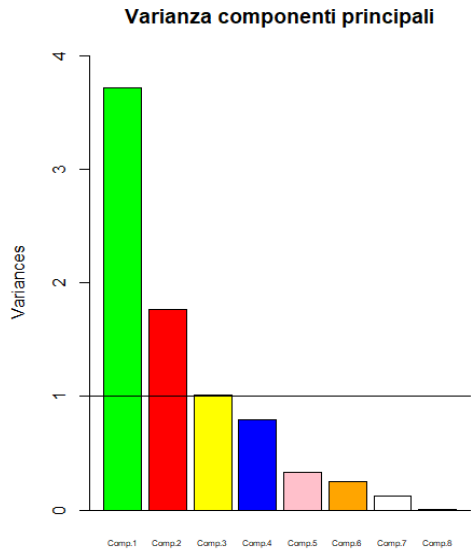

In giallo invece sono evidenziate , nella tabella precedente , le frequenze percentuali cumulate della varianza. Si vede che l'80% è superato dalla terza componente , quindi anche questo criterio conferma la scelta precedente riguardante le componenti principali. In particolare la fedeltà di rappresentazione sui primi tre assi è circa l'81%.

Un altro modo ancora è osservare la matrice di correlazione R, che mette in relazione le variabili originali (*righe*) e le otto componenti (*colonne*).

Dalla matrice in questione , infatti, si può dedurre come le prime tre colonne massimizzino tutti i valori di ogni variabile originale e quindi come esse le rappresentino al meglio.

Tutte e tre le osservazioni suggeriscono di considerare le prime tre componenti principali.

Matrice di correlazione R

```
> R
             [,1]   [,2]   [,3]   [,4]   [,5]   [,6]   [,7]  [,8]
palmitic    0.889  0.066  0.115  0.250  0.309  0.038  0.181 0.016
palmitoleic 0.869  0.320  0.144  0.189  0.080  0.083 -0.271 0.004
stearic    -0.190 -0.343  0.809 -0.419  0.123 -0.015 -0.027 0.004
oleic      -0.953 -0.211 -0.081  0.178 -0.009  0.056 -0.062 0.036
linoleic    0.705  0.456 -0.088 -0.456 -0.232 -0.152  0.027 0.021
linolenic   0.422 -0.804 -0.193  0.088  0.072 -0.348 -0.066 0.001
arachidic   0.440 -0.594 -0.430 -0.429  0.085  0.276 -0.023 0.002
eicosenoic  0.602 -0.538  0.303  0.296 -0.388  0.128  0.048 0.002
```

Analisi dei grafici delle variabili

Si analizzano in seguito i grafici delle variabili prendendo in considerazione i nuovi assi principali.

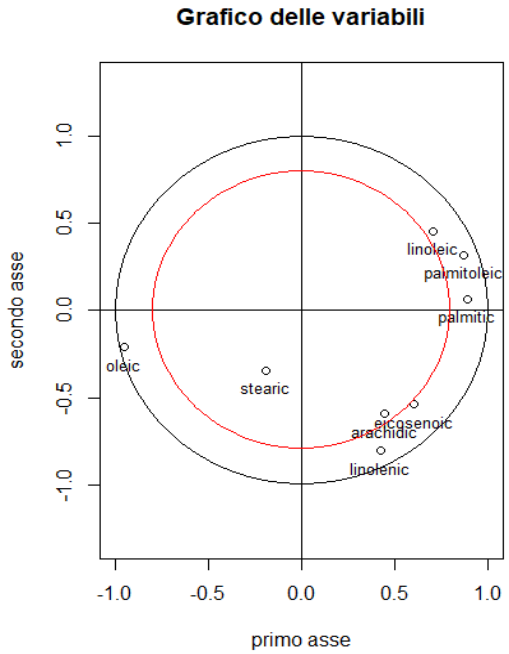

Il seguente grafico mostra che le variabili : *'linoleic'* , *'palmitoleic'* e *'palmitic'* sono correlate positivamente tra loro rispetto alla prima e seconda componente, mentre sono correlate negativamente con *'oleic'* e non correlate alle variabili *'eicosenoic'* , *'linolenic'* e *'arachidic'* che sono , invece , correlate positivamente tra loro.

Osservando anche i valori delle fedeltà delle variabili , la maggior parte di esse , in questo sistema di assi , è ben rappresentata, ad eccezione della variabile *'stearic' e 'arachidic'*

Fedeltà (primo asse , secondo asse) :

palmitic	palmitoleic	stearic	oleic	linoleic	linolenic	arachidic	eicosenoic
0.8914466	0.9260459	0.3921084	0.9760789	0.8396196	0.9080198	0.7392131	0.8073710

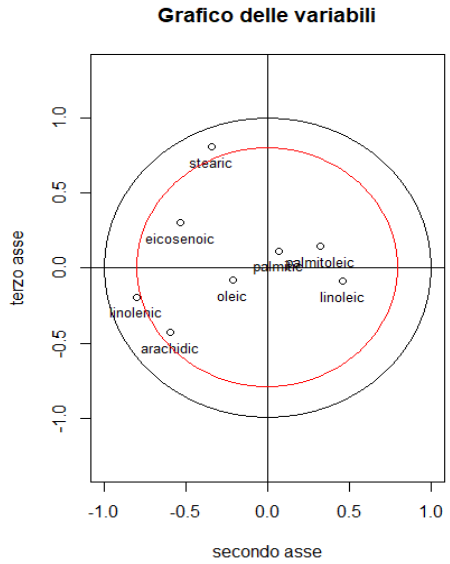

In questo grafico , invece, non sono presenti forti correlazioni tra variabili ad eccezione di una buona correlazione positiva tra la variabile *'linolenic' e 'arachidic'.*

Osservando invece le variabili dentro la circonferenza rossa , che rappresenta la ' *Fedeltà di rappresentazione* ' , e i valori assunti nella tabella sotto riportata, si nota che sono molti gli acidi che non sono rappresentati fedelmente, ad eccezione dell' acido stearico e quello linolenico che hanno una fedeltà rispettivamente del 88% circa ,il primo, e 83% il secondo.

Fedeltà (secondo asse , terzo asse) :

palmitic	palmitoleic	stearic	oleic	linoleic	linolenic	arachidic	eicosenoic
0.1325934	0.3509074	0.8787093	0.2260133	0.4644136	0.8268404	0.7333048	0.6174569

Ora si riporta il grafico delle variabili avente come assi principali il primo e il terzo.

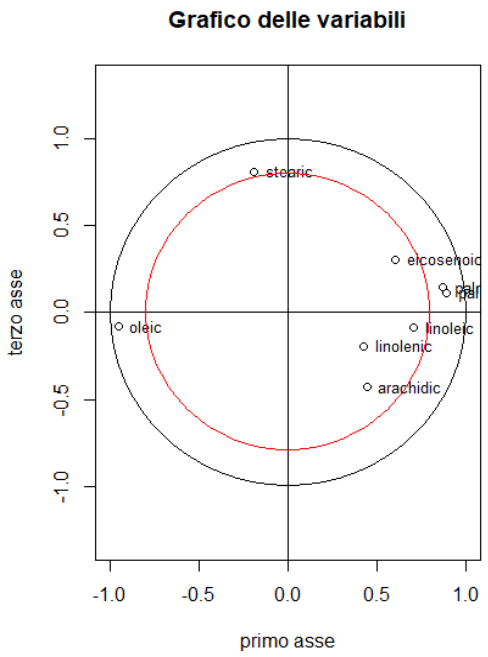

Questa rappresentazione grafica insieme alla prima analizzata, descrivono meglio le variabili originarie.

Si può notare che le variabili *'palmitic' e 'palmitoleic'* sono fortemente correlate positivamente. Una forte correlazione negativa è , invece , tra *'palmitic'* , *'palmitoleic'* e '*oleic*'.

Come detto precedentemente , sono diverse le variabili rappresentate fedelmente tra cui ,come si può anche osservare dalla tabella sotto riportata, *'palmitic', 'palmitoleic'* '*oleic*' e *'stearic'* .

Fedeltà (primo asse , terzo asse) :

palmitic	palmitoleic	stearic	oleic	linoleic	linolenic	arachidic	eicosenoic
0.8964073	0.8808502	0.8310120	0.9564361	0.7104710	0.4640399	0.6152235	0.6739533

Dopo aver analizzato questi tre grafici e i valori delle fedeltà per ogni variabile , si può osservare la miglior rappresentazione per ogni variabile originale.

Partendo dal primo grafico , cioè il piano generato dalla componente uno e dalla componente due, sicuramente con il 97% di fedeltà di rappresentazione , la variabile *'oleic'* è meglio rappresentata, allo stesso modo in questo sistema di assi lo sono anche le variabili : *'palmitoleic'* (92% di fedeltà) , *'linoleic'* (83% di fedeltà), *'linolenic'* (90% di fedeltà) e *'eicosenoic'* (80% di fedeltà).

Il secondo grafico , avente come assi principali la seconda e la terza componente, rappresenta al meglio la variabile *'stearic'* che ha una percentuale di fedeltà pari all'87%.

Infine rimane la variabile *'palmitic'* che è meglio rappresentata nell'ultimo grafico con l'89% di fedeltà.

E' curioso notare che la variabile *'arachidic'* non è rappresentata fedelmente in nessuno dei tre grafici cioè non raggiunge l'80% della fedeltà . Tra questi è meglio rappresentata dal primo grafico con il 73% .

Dallo studio fatto fino ad ora è possibile dedurre anche da quali variabili è meglio descritta ciascuna componente.

In particolare la prima componente principale è caratterizzata dalle seguenti variabili originali : *'palmitic', 'palmitoleic', 'oleic', 'linoleic' e 'eicosenoic'* , la seconda componente principale da : *'linolenic' e 'arachidic'* , e infine la terza assume valori più alti per la variabile *'stearic'.*

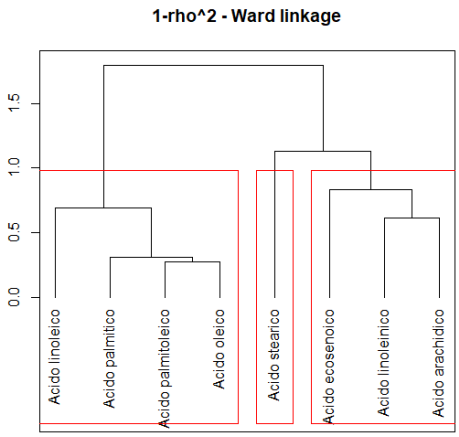

Riprendendo il grafico delle variabili generato dal primo e il secondo asse , si può dire che rappresenta più fedelmente le variabili , ad eccezione dell'acido stearico. Riassumendo le correlazioni di questo primo grafico , risulta che le variabili *'palmtic' , 'palmitoleic' e 'linoleic'* sono soggette a una forte correlazione positiva tra loro e molto negativa ,invece, con *'oleic'* . Le variabili *'eicosenoic'* , *'linolenic'* e *'arachidic'* sono tra loro correlate positivamente. Nulla si può dire dell'acido stearico , in quanto rappresentato poco fedelmente nel grafico in questione.

Tuttavia se si analizzano i grafici successivi si nota che la variabile *'stearic'* risulta sempre scorrelata dalle altre, a conferma dell'analisi fatta nello studio descrittivo delle variabili.

Ora si osservi la cluster analysis che si era fatta delle variabili e tagliando il dendrogramma a tre cluster , che rappresentano lo stesso numero di componenti principali, si conclude che i cluster e i '*gruppi'* delle variabili maggiormente correlate risultano i medesimi.

Analisi rappresentazioni grafiche piane delle unità sperimentali

Ora si riportano le migliori rappresentazioni grafiche piane delle unità sperimentali. I grafici che si analizzeranno mettono in relazione gli oli italiani con la loro provenienza.

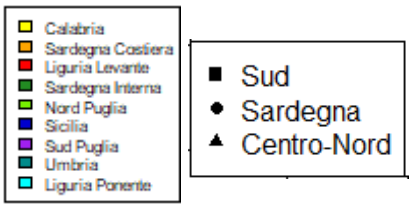

Si riportano le legende separatamente per facilitarne la lettura.

I simboli delle unità sperimentali rappresentate indicheranno la *'Regione'* di provenienza dell'olio, i colori l' *'Area'.*

Osservando i grafici sotto riportati si può dire che la provenienza degli oli influenza la distribuzione delle unità sperimentali, come si era visto anche nell' analisi descrittiva e nella cluster analysis.

Dando una rapida occhiata ai tre grafici, è evidente come il primo asse discrimini gli oli proveniente dal sud (*valori positivi*) rispetto a quelli provenienti dalle altre zone italiane (*valori negativi*).

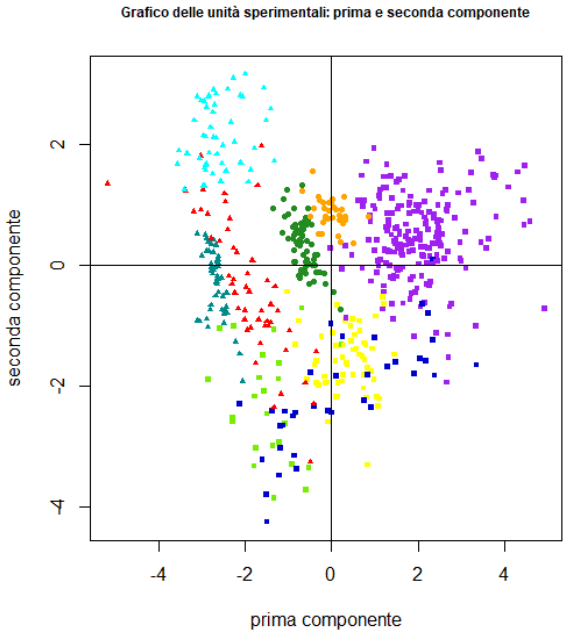

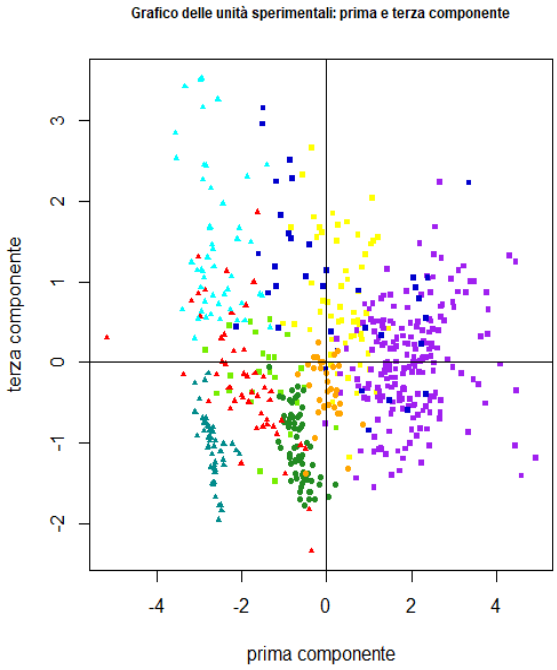

Allo stesso modo si comporta il secondo asse che rappresenta nei suoi valori postivi , la maggior parte degli oli provenienti dalla Sardegna e dall'Italia centro-settentrionale, mentre in quelli negativi gli oli meridionali.

Nel terzo asse ,invece, non si riscontrano caratterizzazioni apprezzabili , a parte il fatto che rappresenta nei suoi valori negativi gli oli di provenienza sarda.

In particolare si osserva che in tutti i grafici gli oli sardi sono rappresentati vicino all'origine degli assi.

È evidente una forte corrrelazione positiva tra la prima componente e gli oli del Sud della Puglia, che si trovano tutti a destra del primo asse. Si nota anche una correlazione positiva della seconda componente con gli oli provenienti dalla Liguria del Ponente che sono a loro volta correlati negativamente con la prima componente. In questi due grafici è anche osservabile una correlazione negativa degli oli Umbri con la prima componente, ricordando che gli oli umbri hanno un'elevata percentuale di acido oleico , il più alto in Italia, e la prima componente è correlata molto negativamente con questo tipo di acido. Alla stessa maniera si fanno le stesse considerazioni per gli oli della Liguria del Levante e gli oli del Nord della Puglia, che sono gli unici oli meridionali a trovarsi a sinistra del primo asse. Si ricorda che si era evidenziato nello studio delle variabili precedente una somiglianza tra gli oli del nord della Puglia e quelli della Liguria , che si ripresenta in queste osservazioni.

In conclusione anche nei grafici di dispersione delle componenti principali è evidente come la provenienza degli oli influenzi la loro distribuzione nel sistema di assi.

Confronto Cluster Analysis e PCA

Ricordando che la distriubuzione nei cluster era la seguente :

Nel primo gruppo, si trovavano oli con un alto livello di concentrazione di acido oleico, infatti, erano costituiti principalmente da oli provenienti dalla parte settentrionale della Puglia, dall'Umbria e dalla zona del levante ligure. Il secondo gruppo si caratterizzava per un'elevata concentrazione di acido stearico, acido linoleico e acido eicosenoico, pertanto era composto principalmente da oli provenienti dalla Sicilia e dalla Calabria. Nel terzo gruppo si riscontravano livelli elevati di acido palmitico e acido palmitoleico, motivo per cui era formato quasi esclusivamente da oli del sud della Puglia. Il quarto gruppo si distingueva per un

baricentro elevato della variabile acido linoleico e della variabile acido arachidico, infatti, era composto interamente da oli sardi. L'ultimo gruppo, il quinto, presentava livelli mediamente alti di acido stearico e acido oleico, mentre aveva livelli praticamente nulli di acido linoleico e acido arachidico, caratteristiche tipiche degli oli provenienti dalla Liguria di Ponente. Ora si osservino le migliori rappresentazioni grafiche piane delle unità sperimentali, dove è indicato a quale gruppo della cluster analysis appartengono , il metodo di aggregazione usato è quello di Ward utilizzzando la distanza euclidea che era risultato il metodo più attendibile.

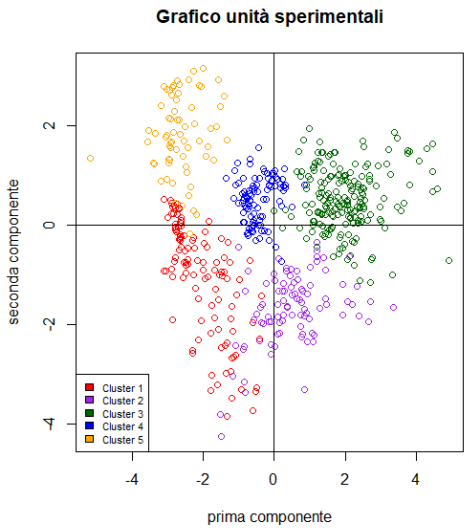

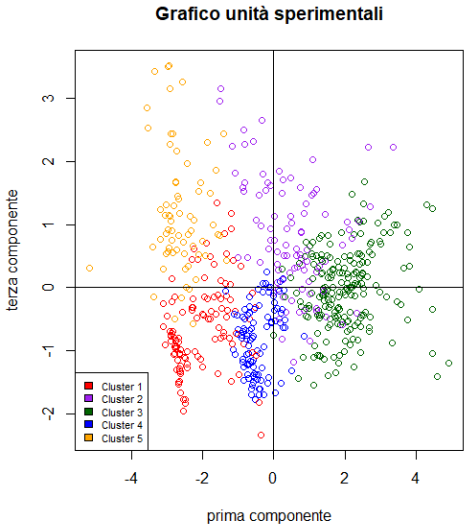

Come si può notare dai seguenti grafici , i gruppi che si sono creati nella cluster analysis vengono distinti nella PCA in base alle diverse correlazioni con gli assi principali . Ad esempio gli oli sardi che sono rappresentati al centro degli assi fanno parte di un unico cluster , il quarto, in quanto sono scorellati , gli oli del sud della puglia ,correlati positivamente con la prima componente , presenti alla sinistra del primo asse fanno parte di un unico cluster , il terzo. Gli oli della liguria del ponente che sono a loro volta correlati negativamente con la prima componente fanno parte di un altro cluster ancora. In base alla correlazione il grafico si tinge di un colore diverso per quadrante , come in particolare si può notare nel primo grafico.

Quindi come nella cluster analysis , anche nella PCA, i gruppi si distinguono in base al tipo di correlazione.

Conclusione :

L'analisi PCA ha ridotto la dimensione dello spazio delle variabili originali, identificando le prime tre componenti principali quelle che rappresentavano meglio le variabili. I grafici basati su queste componenti hanno evidenziato correlazioni tra le variabili e la provenienza degli oli italiani. I gruppi identificati dalla PCA si sono allineati ai risultati della cluster analysis, confermando le relazioni tra componenti principali e gruppi di oli. Complessivamente, l'analisi PCA ha fornito una riduzione dimensionale efficace e ha evidenziato relazioni significative tra le variabili, consentendo una migliore comprensione della struttura dei dati e delle influenze regionali sulle componenti degli oli.