Relazione di tirocinio

Analisi time series su dati di domanda e offerta power

Edoardo Zero

Ottobre 2025

1 Introduzione

Il tirocinio si è svolto tra il 1 luglio 2025 e il 30 settembre 2025 presso *Axpo Italia S.p.A.*, nella sede di Genova, all'interno del reparto di Trading, in particolare, sono stato inserito nel team di *Trading Analytics*. Axpo Italia è parte del gruppo energetico svizzero Axpo, attivo a livello internazionale nella produzione, fornitura e trading di energia elettrica e gas naturale. Il reparto di Trading si occupa principalmente della compravendita di energia sui mercati nazionali e internazionali, con l'obiettivo di ottimizzare i portafogli energetici e gestire i rischi derivanti dall'elevata volatilità dei prezzi. All'interno di questo contesto, il team di Trading Analytics svolge attività di raccolta, elaborazione e interpretazione di dati a supporto del trading, sviluppando strumenti e modelli per valutare diversi scenari di mercato.

2 Descrizione del Progetto

Il tirocinio ha avuto come obiettivo principale lo sviluppo di un modello predittivo per il consumo energetico, a partire dall'elaborazione di dati meteorologici su griglia geografica europea. I dati raccolti sono stati ricondotti alle diverse zone di mercato elettrico (*bidding zones*). Successivamente, le variabili meteorologiche sono state aggregate tenendo conto della distribuzione della popolazione.

Una volta ottenute queste variabili esogene, l'analisi si è concentrata sullo studio delle loro correlazioni con i consumi e sulla costruzione di un modello di previsione che è stato sviluppato per studiare ,in particolare, il mercato francese.

La relazione ripercorre le fasi principali del progetto : dalla raccolta e gestione dei dati, all'analisi descrittiva delle serie storiche, fino allo sviluppo del modello predittivo e alla discussione delle conoscenze acquisite.

3 Raccolta Dati e Studio Geospaziale

L'obiettivo iniziale del progetto, concordato con il tutor aziendale, era la costruzione di un dataset meteorologico su griglia geografica da utilizzare come base per lo sviluppo del modello predittivo. La principale fonte è stata il portale *Copernicus*, programma dell'Unione Europea che fornisce dati climatici e meteorologici attraverso il *Climate Data Store*. In particolare sono stati impiegati i dati *ERA5*, una rianalisi prodotta da *ECMWF* (European Centre for Medium-Range Weather Forecasts) che combina osservazioni storiche con un modello fisico dell'atmosfera, garantendo copertura spaziale e coerenza temporale. Sono state scaricate le variabili di temperatura a 2 metri e pressione superficiale, con risoluzione oraria dal 2013 a settembre 2025.

Data la grande mole di dati e le limitazioni nei download manuali è stato sviluppato un codice basato su API che ha automatizzato il processo di scaricamento, gestendo i file anno per anno. Per collegare i dati climatici alla dimensione demografica è stato utilizzato un dataset di *Eurostat*, che attraverso il servizio *GISCO* (Geographic Information System of the Commission) fornisce informazioni geospaziali e statistiche. In particolare, sono state impiegate le *Local Administrative Units* (LAU), suddivisioni territoriali locali con dati su confini e popolazione. Mediante operazioni di *join geospaziale*, le rilevazioni meteorologiche sono state attribuite prima agli stati e alle zone energetiche interne, e successivamente ai singoli LAU, così da poter pesare le variabili in funzione della popolazione residente. Per le fasi successive lo studio è stato circoscritto alla Francia. Le rilevazioni orarie sono state aggregate su base giornaliera e pesate per la popolazione dei LAU. Il dataset finale di studio comprendeva sei variabili principali: data, temperatura, pressione, HDD (*Heating Degree Days*) e CDD (*Cooling Degree Days*) pesati per popolazione, e la variabile di consumo di energia fornita dal database aziendale di Axpo. Gli indicatori HDD e CDD misurano rispettivamente il fabbisogno energetico per il riscaldamento e per il raffrescamento. Essi vengono definiti come:

$$HDD = \max(0,\, T_{\text{ref}} - T)$$

$$CDD = \max(0,\, T - T_{\text{ref}})$$

dove T rappresenta la temperatura media giornaliera e $T_{ref} = 18°C$ è la soglia di riferimento comunemente utilizzata.

La figura 1 mostra la griglia meteorologica sovrapposta ai confini europei.

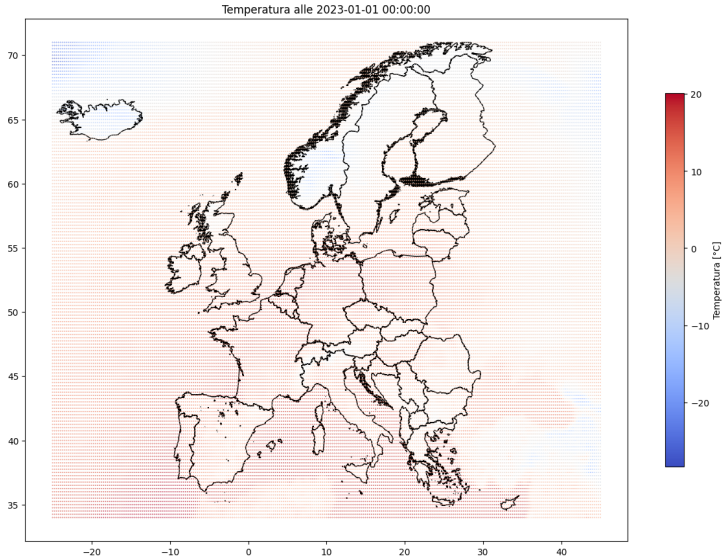

Figura 1: Griglia meteorologica di Copernicus con sovrapposizione dei confini europei.

la Figura 2 riporta un esempio per un singolo stato , in questo caso per la Germania.

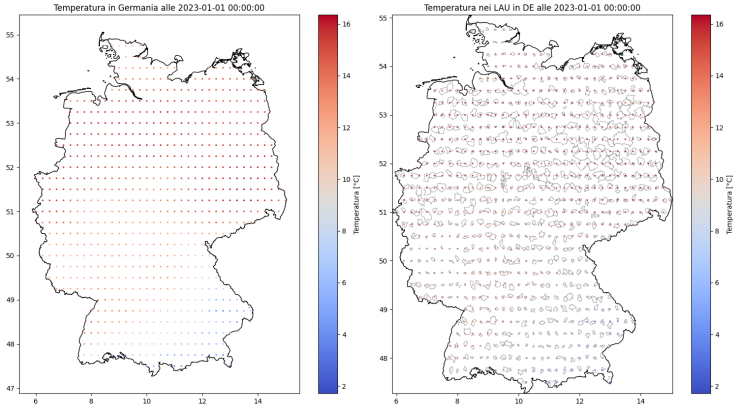

Figura 2: Germania: a sinistra l'attribuzione delle rilevazioni al paese, a destra l'associazione ai singoli LAU.

4 Analisi delle Serie Storiche

L'analisi descrittiva ha lo scopo di mettere in evidenza le caratteristiche principali delle serie : trend, stagionalità, distribuzioni e relazioni con i valori passati così da comprendere meglio il comportamento dei dati prima della fase di modellizzazione.

Poiché l'obiettivo finale è lo sviluppo di un modello di previsione della domanda elettrica, è stato necessario valutare anche le proprietà delle variabili esogene. Infatti, per poter stimare correttamente il forecast del consumo, occorre disporre anche di previsioni delle variabili esplicative.

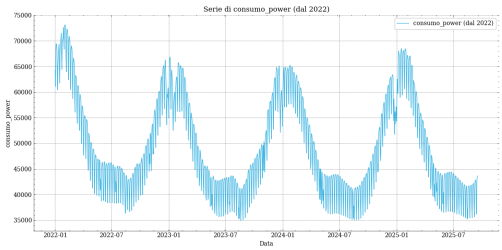

(a) Serie del consumo elettrico: dettaglio su un periodo ristretto.

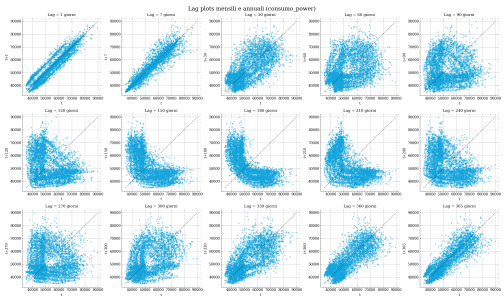

(b) Lag plots del consumo elettrico.

Figura 3: Analisi descrittiva della serie di consumo elettrico.

La serie storica del consumo elettrico francese, misurata in MWh/h e fornita come variabile `actual`, rappresenta la variabile target del modello di previsione. Per osservarne le caratteristiche principali sono stati analizzati i dati in un periodo ristretto, così da evidenziare meglio i pattern ricorrenti.

- una chiara stagionalità annuale, con consumi elevati nei mesi invernali e valori più bassi in estate, coerente con il maggiore fabbisogno energetico per il riscaldamento;
- una stagionalità settimanale, visibile nel dettaglio dei dati giornalieri, legata alle diverse abitudini di consumo tra giorni feriali e weekend.

Si osservano inoltre picchi e cadute riconducibili a festività nazionali: in particolare, i consumi si riducono durante il periodo natalizio e intorno al 15 agosto (festività dell'*Assomption*), confermando come eventi socio-economici abbiano un impatto diretto sulla domanda elettrica. L'analisi dei lag plot (Figura 3b) conferma la presenza di una forte autocorrelazione:

- ai lag brevi (1 giorno) la relazione è quasi lineare, indicando che il consumo di un giorno è fortemente dipendente dal giorno precedente;

- al lag settimanale (7 giorni) emerge una struttura regolare, in linea con la stagionalità settimanale;
- ai lag annuali (365 giorni) si osserva nuovamente una forte correlazione, legata alla ciclicità stagionale;
- ai lag intermedi (30–240 giorni) la dispersione assume una forma ad imbuto, che riflette la variabilità tra periodi estivi e invernali.

In sintesi, la serie del consumo elettrico presenta una forte stagionalità annuale e settimanale ed è sensibile a festività nazionali.

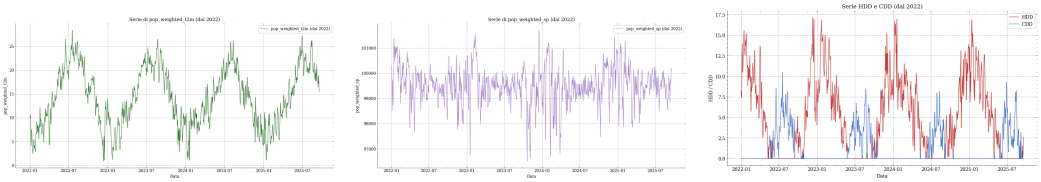

(a) Temperatura (b) Pressione (c) HDD e CDD

Figura 4: Serie storiche delle variabili esogene considerate nello studio.

La temperatura mostra un chiaro andamento stagionale, con valori elevati nei mesi estivi e più bassi in inverno, in linea con l'andamento climatico atteso (Figura 4a). Si tratta della principale variabile esplicativa del consumo elettrico, poiché la domanda di energia è strettamente legata alle esigenze di riscaldamento e raffrescamento.

L'HDD risulta elevato nei mesi freddi, mentre il CDD cresce nei mesi estivi (Figura 4c). Ai fini di previsione, il loro forecast è stato ricavato applicando le formule di definizione ai valori previsti della temperatura, senza stimare direttamente modelli specifici per queste variabili. Per quanto riguarda la temperatura e la pressione è stato effettuato lo studio sulla stazionarietà e confrontando i correlogrammi dell'ACF e PACF , la funzione auto.arima() e il grafico dei residui è stato possibile individuare il processo generatore dei dati da cui è stato effettuato un forecast di 30 giorni.

Per valutare il legame tra consumo energetico e variabili esogene è stata calcolata la correlazione di Pearson e sono state rappresentate graficamente le relazioni mediante *scatter plot*. L'analisi ha evidenziato che:

- la temperatura risulta fortemente correlata negativamente con i consumi ($r = -0.82$), indicando che a valori più bassi di temperatura corrispondono maggiori consumi energetici;

- gli HDD sono correlati positivamente con il consumo ($r = 0.86$), confermando il legame diretto tra necessità di riscaldamento e domanda elettrica;
- le variabili pressione e CDD non mostrano una correlazione significativa con i consumi, risultando sostanzialmente scorrelate.

5 Modello di Previsione

Per la fase di modellizzazione è stato scelto *LightGBM* (*Light Gradient Boosting Machine*), un algoritmo di *gradient boosting* basato su alberi decisionali. Si tratta di un modello particolarmente efficiente nel trattamento di dataset di grandi dimensioni.

LightGBM presenta diversi vantaggi :

- è scalabile e ottimizzato per gestire grandi volumi di dati, garantendo tempi di addestramento ridotti;
- consente di integrare in maniera naturale variabili esogene;
- offre elevate prestazioni predittive, anche in contesti complessi come il mercato elettrico, caratterizzato da forte stagionalità e variabilità.

L'utilizzo di un modello di questo tipo risulta coerente con le esigenze del settore energetico. Negli ultimi anni, infatti, i mercati elettrici europei hanno visto un aumento della granularità temporale degli scambi infatti sono stati introdotti contratti *quarter-hourly* (15 minuti). In questo contesto, modelli veloci e aggiornabili come LightGBM risultano particolarmente adatti, poiché permettono di catturare dinamiche di breve periodo e fornire previsioni in tempi rapidi, requisito fondamentale nelle attività operative e di trading.

Per adattare il modello LightGBM è stato necessario introdurre un insieme di *feature temporali* che permettessero di catturare le dinamiche legate al tempo e alle festività. Le nuove variabili create possono essere suddivise in :

- **Feature calendariali**: variabili derivate dalla colonna delle date, come mese, giorno del mese, giorno dell'anno, giorno della settimana e anno. Sono stati inoltre introdotti indicatori binari per distinguere weekend, inizio e fine del mese. È stata aggiunta una feature che identifica le festività francesi (calendario ufficiale), oltre a un'estensione del periodo natalizio (20 dicembre - 6 gennaio) evidenziato come particolarmente rilevante dall'analisi descrittiva.

- **Feature derivate dai consumi passati**: statistiche mobili come medie mobili e deviazioni standard (*rolling mean* e *rolling standard deviation*) su finestre temporali di diversa ampiezza (da una settimana a un anno), medie mobili esponenziali (*exponential weighted mean*), che attribuiscono maggior peso ai valori più recenti.

1. Inizializzazione
$$f_0(x) = \arg\min_{\gamma} \sum_{i=1}^{N} L(y_i, \gamma).$$

2. For $m = 1$ to M:

   (a) For $i = 1, 2, \ldots, N$ calcola
$$r_{im} = -\left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)}\right]_{f=f_{m-1}}.$$

   (b) Adatta un albero di regressione ai valori target r_{im} , ottenendo regioni terminali A_{jm}, $j = 1, 2, \ldots, J_m$.

   (c) For $j = 1, 2, \ldots, J_m$ calcola
$$\hat{\gamma}_{jm} = \arg\min_{\gamma} \sum_{x_i \in A_{jm}} L(y_i, f_{m-1}(x_i) + \gamma).$$

   (d) Aggiornamento del modello
$$f_m(x) = f_{m-1}(x) + \nu \sum_{j=1}^{J_m} \hat{\gamma}_{jm} \mathbf{1}_{\{x \in A_j\}}.$$

3. Output $\hat{f}(x) = f_M(x)$.

Una volta definite le feature, i dati sono stati suddivisi in tre insiemi: *train set* (dal 2013 al 2021), *validation set* (anno 2022) e *test set* (dal 2023 in poi). Questa scelta consente di addestrare il modello su un ampio periodo, monitorarne le prestazioni su dati non visti e, infine testarne la capacità predittiva su un arco temporale più recente.

Come metrica di valutazione è stato utilizzato il *Mean Absolute Error* (MAE), ossia la media degli scarti assoluti tra valori osservati e predetti, il vantaggio di questa misura è l'immediata interpretabilità.

Durante il training è stata adottata la tecnica dell'*early stopping*, monitorando la metrica sul validation set. Questo ha permesso di identificare la

best iteration, ovvero il numero di alberi ottimale costruito dal modello, il punto in cui le prestazioni raggiungono il massimo senza rischiare di incorrere nell'overfitting. In questo modo il modello mantiene una buona capacità di generalizzazione.

Per analizzare il contributo delle diverse variabili predittive è stata valutata l'importanza delle feature secondo due criteri: *gain* e *split*. Il *gain* misura la riduzione media della funzione di perdita ottenuta quando una feature viene utilizzata per uno split (indicatore qualitativo dell'importanza), mentre lo *split* indica il numero di volte in cui quella variabile è stata effettivamente scelta negli alberi.

I risultati hanno evidenziato come le feature più rilevanti fossero le medie mobili del consumo (`roll_mean` ed `ewm`), insieme ad alcune feature temporali come il giorno della settimana. Tra le variabili esogene, spiccano gli indici climatici (`HDD` e `t2m`), confermando il legame tra consumi e temperatura. Al contrario, la pressione atmosferica (`sp`) si è rivelata poco informativa, coerentemente con quanto già osservato nell'analisi descrittiva. I risultati ottenuti sul *test set* mostrano un buon adattamento del modello, in particolare:

- **MAE (Mean Absolute Error)**: 975, che rappresenta in media l'errore assoluto commesso dal modello in unità della variabile target. Considerando che i valori di consumo oscillano tra 35.000 e 90.000 MWh/h, si tratta di un errore contenuto.

- $\mathbf{R^2}$: 0.974.

Dal confronto tra valori reali e predetti sul test set emerge che il modello è in grado di riconoscere correttamente i principali pattern stagionali e le variazioni legate a eventi specifici, come i periodi festivi (ad esempio Natale e Ferragosto).

Dopo aver validato il modello, è stato implementato un forecast operativo per i 30 giorni successivi. A questo scopo, sono stati utilizzati i valori previsionali delle variabili esogene e, per la variabile target, è stata adottata una strategia ricorsiva: la predizione di un giorno è stata utilizzata come input per calcolare la previsione del giorno successivo. Questa procedura consente di estendere il forecast anche in assenza dei valori osservati del consumo reale, al costo di una propagazione dell'errore.

6 Conoscenze Acquisite

Grazie al tirocinio ho avuto la possibilità di approfondire in maniera significativa le mie competenze nel linguaggio `Python`, in particolare attraverso

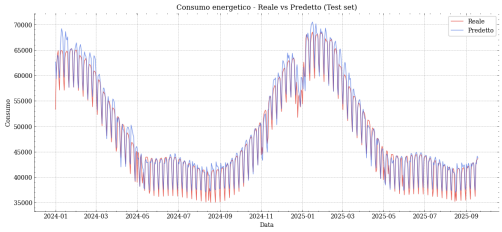

(a) Confronto tra valori reali e predetti (Test set).

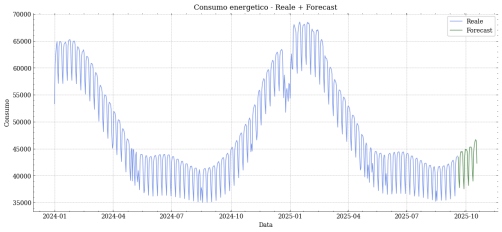

(b) Forecast a 30 giorni del consumo elettrico in Francia.

Figura 5: Prestazioni del modello sul test set e previsione operativa a 30 giorni.

l'utilizzo di numerosi pacchetti per l'analisi e la modellizzazione dei dati. Tra i più rilevanti si possono citare: `pandas`, `numpy`, `geopandas`, `xarray`, `matplotlib`, `statsmodels`, e `lightgbm`. L'esperienza mi ha permesso di acquisire dimestichezza non solo con la gestione di dataset complessi (in particolare dati meteorologici su griglie spaziali), ma anche con librerie specifiche per l'analisi di serie temporali e la loro validazione statistica.

Ho potuto , inoltre, consolidare le conoscenze teoriche sulle *serie storiche*. Ho avuto l'opportunità di sperimentare modelli predittivi non tradizionali per le serie storiche, basati su approcci di *Machine Learning*, che fino ad ora non avevo mai applicato in maniera concreta.

L'esperienza in azienda ha rappresentato ,già di per sè, un'ulteriore aspetto formativo: frequentando gli uffici di Axpo sono entrato in contatto con una realtà estremamente stimolante e dinamica, caratterizzata da persone giovani motivate e molto competenti .