Montisci Matteo , Scibilia Tommaso , Zero Edoardo

RELAZIONE MODELLI LINEARI GENERALIZZATI

Introduzione al Dataset

I dati analizzati in questo laboratorio sono stati rilevati tramite il sondaggio *"Fiji Fertility Survey"* e riguardano l'utilizzo di contraccettivi da parte di un campione di 1607 donne sposate e in età fertile.

Le variabili prese in considerazione sono :

- *age :* la fascia di età suddivisa in quattro livelli *(<25 , 25-29 , 30-39, 40-49)*;
- *education :* livello di educazione (*high , low)*;
- *wantsMore :* volontà di aver figli *(Yes , No)* ;
- *notUsing :* numero di donne che non utilizzano contraccettivi;
- *using :* numero di donne che utilizzano contracettivi;

L'obbiettivo dello studio è ricostruire dei modelli lineari generalizzati per studiare l'uso di contraccettivi in dipendenza dalla fascia di età , dal livello di educazione e dalla volontà di aver figli.

Inizialmente sono state create due nuove variabili : la prima *total* data dalla somma di *using* e *notUsing* , la seconda *p_using = using / total* . In questo modo si può osservare la distribuzione in percentuale delle donne che utilizzano contracettivi nei diversi livelli delle variabili esplicative.

Analisi Descrittiva

Essendo la variabile di studio dicotomica (utilizzo contracettivi : *sì/no*) si è proceduto a calcolare la percentuale delle donne che usano dei contracettivi. Dalla tabella sotto riportata si osserva che solo il 31.5% delle donne sottoposte al sondaggio utilizza contracettivi :

total_notUsing	total_using	total	p_using
1100	507	1607	0.315496

In seguito, si sono suddivise le osservazioni nei diversi livelli delle variabili esplicative per studiare la percentuale di utilizzo di contraccettivi nelle diverse classi.

age	education	wantsMore	notUsing	using	total	p_using
<25	low	yes	53	6	59	0.101695
<25	low	no	10	4	14	0.285714
<25	high	yes	212	52	264	0.19697
<25	high	no	50	10	60	0.166667
25-29	low	yes	60	14	74	0.189189
25-29	low	no	19	10	29	0.344828
25-29	high	yes	155	54	209	0.258373
25-29	high	no	65	27	92	0.293478
30-39	low	yes	112	33	145	0.227586
30-39	low	no	77	80	157	0.509554
30-39	high	yes	118	46	164	0.280488
30-39	high	no	68	78	146	0.534247
40-49	low	yes	35	6	41	0.146341
40-49	low	no	46	48	94	0.510638
40-49	high	yes	8	8	16	0.5
40-49	high	no	12	31	43	0.72093

È interessante osservare che la percentuale minore (10.1%) di donne che utilizzano contraccettivi sono coloro che hanno meno di 25 anni, istruzione bassa e vogliono avere dei figli.

Mentre la percentuale maggiore (72.0%) si riscontra nella fascia di età tra 40 e 49 anni , con un'istruzione alta e che non vogliono avere figli.

In generale sembrerebbe che la percentuale di donne che utilizzano i contraccettivi sia più alta con il crescere della fascia di età. Inoltre, si osserva che in quasi tutti i gruppi la percentuale delle donne è maggiore per quelle che non vogliono avere figli.

age	sum_notUsing	sum_using	sum_total	p_using
25-29	299	105	404	0.259901
30-39	375	237	612	0.387255
40-49	101	93	194	0.479381
<25	325	72	397	0.18136

Tabella distribuzione percentuale suddivisa per fasce d'età

wantsMore	sum_notUsing	sum_using	sum_total	p_using
no	347	288	635	0.453543
yes	753	219	972	0.225309

Tabella distribuzione percentuale suddivisa per il desiderio di avere figli

Le due tabelle analizzate forniscono evidenze coerenti con quanto dedotto in precedenza. La prima mostra come la percentuale di donne che utilizzano metodi contraccettivi tenda ad aumentare con l'avanzare dell'età, evidenziando una relazione positiva tra l'età e l'adozione di tali metodi. La seconda tabella, invece, mette in luce un altro aspetto significativo: la percentuale di utilizzo di contraccettivi cresce tra le donne che dichiarano di non voler avere figli.

In seguito, l'analisi è stata approfondita graficando degli istogrammi.

Istogramma 1

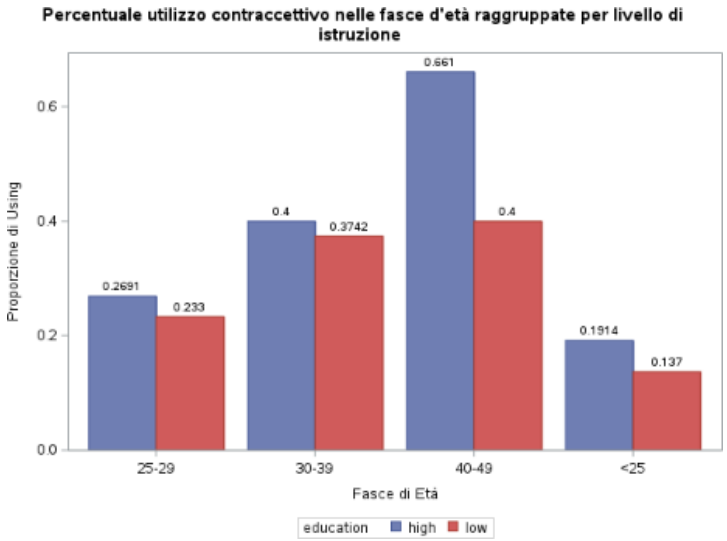

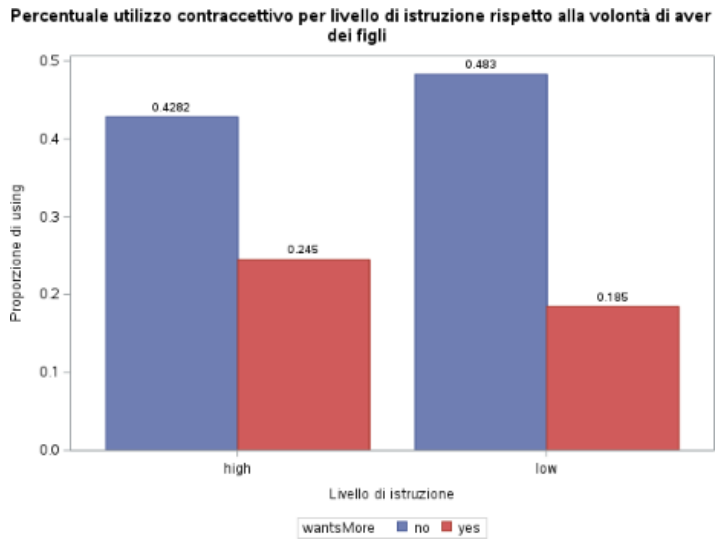

Istogramma 2

L'analisi *dell'Istogramma 1* conferma ancora una volta che la percentuale di donne che utilizzano metodi contraccettivi cresce con l'aumentare dell'età. Inoltre, emerge chiaramente come, all'interno di tutte le fasce di età considerate, la percentuale di utilizzo sia maggiore tra le donne con un livello di istruzione alto rispetto a quelle con istruzione bassa.

Anche nel caso dell'*Istogramma 2* si conferma che le donne che non desiderano avere figli mostrano una percentuale di utilizzo di contraccettivi più alta rispetto a quelle che desiderano avere bambini. Tuttavia, si osserva un dato rilevante: tra le donne che non desiderano figli, l'utilizzo di contraccettivi risulta maggiore in quelle con un basso livello di istruzione rispetto a quelle con istruzione alta. Un ulteriore aspetto degno di nota è che, tra le donne che desiderano avere figli, l'utilizzo di contraccettivi è più basso tra quelle con istruzione bassa rispetto a quelle con istruzione alta.

Implementazione del modello binomiale (o regressione logistica)

È stata considerata come variabile risposta il vettore **Y** dove **∀ i**

$Y_i \sim Bern(p_i)$ $\quad E(Y_i) = \mu_i = p_i$

con $\mathbf{p_i}$ la proporzione di donne che usano i contraccettivi (***using/using+notUsing***).

Come prima cosa si è costruito quindi, un modello binomiale, applicando la procedura GENMOD con la link function canonica *logit*.

```
Proc genmod data=contraccettivi;
    class age education wantsMore;
    model using/total = age education wantsMore / link= logit cl;
run;
```

Tra i risultati dell'output di SAS si può subito osservare che meno di un terzo delle donne fa uso di contraccettivi (507 su un totale di 1607), confermando quanto detto prima con l'analisi descrittiva.

Profilo di risposta		
Valore ordinato	Esito binario	Frequenza totale
1	Evento	507
2	Non evento	1100

Il modello ottenuto utilizza un totale di nove parametri: uno per l'intercetta, quattro per i livelli di *age*, 2 per *education* e altri due per *wantsMore*.

SAS, di default, ridefinisce i parametri e riparametrizza il modello imponendo nullo, per ciascuna variabile categorica, il coefficiente relativo all'ultimo livello.

Informazioni sui parametri				
Parametro	Effetto	age	education	wantsMore
Prm1	Intercept			
Prm2	age	25-29		
Prm3	age	30-39		
Prm4	age	40-49		
Prm5	age	<25		
Prm6	education		high	
Prm7	education		low	
Prm8	wantsMore			no
Prm9	wantsMore			yes

Analisi delle stime dei parametri di massima verosimiglianza								
Parametro		DF	Stima	Errore standard	Limiti di confidenza di Wald al 95%		Chi-quadrato di Wald	Pr > ChiQuadr
Intercept		1	-1.9662	0.1720	-2.3033	-1.6290	130.63	<.0001
age	25-29	1	0.3894	0.1759	0.0447	0.7340	4.90	0.0268
age	30-39	1	0.9086	0.1646	0.5860	1.2313	30.46	<.0001
age	40-49	1	1.1892	0.2144	0.7690	1.6095	30.76	<.0001
age	<25	0	0.0000	0.0000	0.0000	0.0000	.	.
education	high	1	0.3250	0.1240	0.0819	0.5681	6.87	0.0088
education	low	0	0.0000	0.0000	0.0000	0.0000	.	.
wantsMore	no	1	0.8330	0.1175	0.6027	1.0632	50.28	<.0001
wantsMore	yes	0	0.0000	0.0000	0.0000	0.0000	.	.
Scala		0	1.0000	0.0000	1.0000	1.0000		

Osservando i test di nullità dei singoli parametri, a livello 5% si rifiuta l'ipotesi di nullità per tutti i parametri, mentre a livello 1% si considera nulla solo la variabile age nell'intervallo 25-29. Non è stato, quindi, ritenuto utile provare a ridurre il modello effettuando un test per un sottoinsieme di coefficienti.

Il modello sembra buono, per valutare la bontà di adattamento si possono osservare i valori ottenuti attraverso diversi criteri, come la devianza, l'AIC e il BIC, e confrontarli con quelli ottenuti utilizzando altri modelli, per vedere se è possibile trovarne uno più conforme ai dati.

A questo punto, quindi, si è applicata la procedura GENMOD con link function diverse da quella canonica, per ottenere, così, nuovi differenti modelli binomiali.
Le link function prese in considerazione sono: l'**identità**, la funzione ***"probit"*** e la funzione ***"clog-log"***, e per ognuna di esse sono stati calcolati i valori per valutare la bontà di adattamento dei modelli corrispondenti.

È possibile ora confrontare i nuovi risultati ottenuti con quelli precedenti.

Criteri di valutazione della bontà di adattamento			
Criterio	DF	Valore	Valore/DF
Devianza	10	29.9172	2.9917
Dev. scalata	10	29.9172	2.9917
Chi-quadrato di Pearson	10	28.2883	2.8288
X2 Pearson scal.	10	28.2883	2.8288
Log verosimiglianza		-933.9192	
Log verosimiglianza piena		-50.7126	
AIC (minore è meglio)		113.4251	
AICC (minore è meglio)		122.7585	
BIC (minore è meglio)		118.0607	

Link function "logit"

Criteri di valutazione della bontà di adattamento			
Criterio	DF	Valore	Valore/DF
Devianza	10	35.6146	3.5615
Dev. scalata	10	35.6146	3.5615
Chi-quadrato di Pearson	10	33.2110	3.3211
X2 Pearson scal.	10	33.2110	3.3211
Log verosimiglianza		-936.7679	
Log verosimiglianza piena		-53.5612	
AIC (minore è meglio)		119.1225	
AICC (minore è meglio)		128.4558	
BIC (minore è meglio)		123.7580	

Link function "identity"

Criteri di valutazione della bontà di adattamento			
Criterio	DF	Valore	Valore/DF
Devianza	10	31.0806	3.1081
Dev. scalata	10	31.0806	3.1081
Chi-quadrato di Pearson	10	29.2915	2.9291
X2 Pearson scal.	10	29.2915	2.9291
Log verosimiglianza		-934.5009	
Log verosimiglianza piena		-51.2943	
AIC (minore è meglio)		114.5885	
AICC (minore è meglio)		123.9218	
BIC (minore è meglio)		119.2240	

Link function "probit"

Criteri di valutazione della bontà di adattamento			
Criterio	DF	Valore	Valore/DF
Devianza	10	27.2313	2.7231
Dev. scalata	10	27.2313	2.7231
Chi-quadrato di Pearson	10	25.8568	2.5857
X2 Pearson scal.	10	25.8568	2.5857
Log verosimiglianza		-932.5762	
Log verosimiglianza piena		-49.3696	
AIC (minore è meglio)		110.7392	
AICC (minore è meglio)		120.0726	
BIC (minore è meglio)		115.3748	

Link function "CLL"

Osservando i valori della devianza, dell'AIC e del BIC dei 4 modelli considerati si può arrivare subito alla conclusione che il modello con l'identità come link function sia il peggiore di tutti, presenta, infatti, i valori maggiori per tutti e 3 gli indici.

Il modello con la link function *"probit"* presenta risultati leggermente più grandi del modello costruito con la link function canonica, risulta, quindi, meno accurato del secondo.

I valori più bassi (e quindi i migliori) della devianza, dell'AIC e del BIC si ottengono con la link function *"clog-log"*, per questo motivo si considera il modello creato con quest'ultima come quello che adatta meglio i dati.

Sono riportati i valori dei p_i, con i rispettivi residui, predetti dal modello con link function *"clog-log"* .

Oss	age	education	wantsMore	notUsing	using	total	predicted_values	residuals
1	<25	low	yes	53	6	59	0.12751	-1.52337
2	<25	low	no	10	4	14	0.23706	0.68121
3	<25	high	yes	212	52	264	0.16210	9.20566
4	<25	high	no	50	10	60	0.29587	-7.75246
5	25-29	low	yes	60	14	74	0.17457	1.08182
6	25-29	low	no	19	10	29	0.31651	0.82127
7	25-29	high	yes	155	54	209	0.22021	7.97516
8	25-29	high	no	65	27	92	0.38944	-8.82824
9	30-39	low	yes	112	33	145	0.25768	-4.36406
10	30-39	low	no	77	80	157	0.44625	9.93819
11	30-39	high	yes	118	46	164	0.32046	-6.55475
12	30-39	high	no	68	78	146	0.53527	-0.14953
13	40-49	low	yes	35	6	41	0.31015	-6.71607
14	40-49	low	no	46	48	94	0.52118	-0.99130
15	40-49	high	yes	8	8	16	0.38206	1.88702
16	40-49	high	no	12	31	43	0.61511	4.55022

Si è utilizzata, ora, un'altra procedura per implementare modelli binomiali: la ***proc logistic***.

Sono stati considerati due modelli, entrambi con link function canonica, che differenziano per il tipo di parametrizzazione effettuata.

Il primo modello è stato parametrizzato con il comando ***PARAM=ref,*** ovvero partendo da una sottomatrice di X e non imponendo vincoli sui coefficienti.

Nel secondo, invece, la parametrizzazione è stata ottenuta con l'opzione ***effect*** (default SAS), che impone vincoli tali che la sommatoria dei parametri dei livelli di ogni variabile categorica sia uguale a 0 ($\Sigma_{i=1}^{S} a_i = 0$).

Informazioni sui livelli di classificazione				
Classe	Valore	Variabili di disegno		
age	25-29	1	0	0
	30-39	0	1	0
	40-49	0	0	1
	<25	0	0	0
education	high	1		
	low	0		
wantsMore	no	1		
	yes	0		

Parametrizzazione REF

Informazioni sui livelli di classificazione				
Classe	Valore	Variabili di disegno		
age	25-29	1	0	0
	30-39	0	1	0
	40-49	0	0	1
	<25	-1	-1	-1
education	high	1		
	low	-1		
wantsMore	no	1		
	yes	-1		

Parametrizzazione EFFECT

Analizzando e confrontando i risultati delle due ***proc logistic*** con diversa parametrizzazione (riportati sotto), si osserva che:

- i valori dell'AIC sono uguali in entrambe le parametrizzazioni e hanno lo stesso valore ottenuto in precedenza con la *proc genmod*
- anche i risultati dei test di nullità dei singoli coefficienti sono uguale a quelli calcolati in precedenza; a livello 5%, quindi, si rifiuta l'ipotesi di nullità per tutti i parametri in entrambe le parametrizzazioni
- i valori degli odds-ratio sono gli stessi e quindi non dipendono dalla parametrizzazione
- l'unica differenza tra i due modelli sono le stime di massima verosimiglianza dei parametri, causata dai diversi vettori dei parametri delle due parametrizzazioni.

Statistiche di bontà del modello			
		Intercetta e covariate	
Criterio	Solo intercetta	Log verosimiglianza	Log verosimiglianza piena
AIC	2005.694	1879.838	113.425
SC	2011.076	1912.131	145.718
-2 Log L	2003.694	1867.838	101.425

Analisi delle stime della massima verosimiglianza						
Parametro		DF	Stima	Errore standard	Chi-quadrato di Wald	Pr > ChiQuadr
Intercept		1	-1.9662	0.1720	130.6250	<.0001
age	25-29	1	0.3894	0.1758	4.9028	0.0268
age	30-39	1	0.9086	0.1646	30.4634	<.0001
age	40-49	1	1.1892	0.2144	30.7581	<.0001
education	high	1	0.3250	0.1240	6.8653	0.0088
wantsMore	no	1	0.8330	0.1175	50.2787	<.0001

Stime degli odds ratio			
Effetto	Stima puntuale	Limiti di confidenza di Wald al 95%	
age 25-29 rispetto a <25	1.476	1.046	2.083
age 30-39 rispetto a <25	2.481	1.797	3.426
age 40-49 rispetto a <25	3.285	2.158	5.000
education high rispetto a low	1.384	1.085	1.765
wantsMore no rispetto a yes	2.300	1.827	2.896

Parametrizzazione REF

Statistiche di bontà del modello			
		Intercetta e covariate	
Criterio	Solo intercetta	Log verosimiglianza	Log verosimiglianza piena
AIC	2005.694	1879.838	113.425
SC	2011.076	1912.131	145.718
-2 Log L	2003.694	1867.838	101.425

Analisi delle stime della massima verosimiglianza						
Parametro		DF	Stima	Errore standard	Chi-quadrato di Wald	Pr > ChiQuadr
Intercept		1	-0.7654	0.0625	149.9331	<.0001
age	25-29	1	-0.2324	0.1045	4.9510	0.0261
age	30-39	1	0.2868	0.0865	10.9877	0.0009
age	40-49	1	0.5674	0.1291	19.3046	<.0001
education	high	1	0.1625	0.0620	6.8653	0.0088
wantsMore	no	1	0.4165	0.0587	50.2787	<.0001

Stime degli odds ratio			
Effetto	Stima puntuale	Limiti di confidenza di Wald al 95%	
age 25-29 rispetto a <25	1.476	1.046	2.083
age 30-39 rispetto a <25	2.481	1.797	3.426
age 40-49 rispetto a <25	3.285	2.158	5.000
education high rispetto a low	1.384	1.085	1.765
wantsMore no rispetto a yes	2.300	1.827	2.896

Parametrizzazione EFFECT

Analizzando le ultime due tabelle si può osservare che i valori degli odds-ratio sono tutti maggiore di 1, questo vuol dire che:

- la percentuale di donne che usa contraccettivi nelle fascia di età 25-29, 30-39 e 40-49 è maggiore rispetto a quella delle donne di età inferiore di 25 anni,
- la percentuale di donne che usa contraccettivi è maggiore per le donne con un livello di istruzione alto,
- le donne senza volontà di avere figli hanno più probabilità di usare contraccettivi rispetto alle restanti.

E' importante osservare che anche gli estremi inferiori degli intervalli di confidenza degli odds-radio sono tutti maggiori di 1, perciò tutti i valori sono significativi a livello 95%.

Design matrix e parametri

Di seguito sono riportate le design matrix e i corrispondenti vettori dei parametri per le due parametrizzazioni considerate.

- **PARAM=EFFECT**

$$\underset{16\times 6}{X} = \begin{bmatrix} 1 & 1 & 0 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 & 1 & -1 \\ 1 & 1 & 0 & 0 & -1 & 1 \\ 1 & 1 & 0 & 0 & -1 & -1 \\ 1 & 0 & 1 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 1 & -1 \\ 1 & 0 & 1 & 0 & -1 & 1 \\ 1 & 0 & 1 & 0 & -1 & -1 \\ 1 & 0 & 0 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 & -1 \\ 1 & 0 & 0 & 1 & -1 & 1 \\ 1 & 0 & 0 & 1 & -1 & -1 \\ 1 & -1 & -1 & -1 & 1 & 1 \\ 1 & -1 & -1 & -1 & 1 & -1 \\ 1 & -1 & -1 & -1 & -1 & 1 \\ 1 & -1 & -1 & -1 & -1 & -1 \end{bmatrix}$$

VINCOLI

- $\delta_{<25} = -\delta_{25-29} - \delta_{30-39} - \delta_{40-49}$
- $\gamma_{low} = -\gamma_{high}$
- $\beta_{yes} = -\beta_{no}$

$$\theta = \begin{bmatrix} \mu \\ \delta_{25-29} \\ \delta_{30-39} \\ \delta_{40-49} \\ \gamma_{high} \\ \beta_{no} \end{bmatrix}$$

- **PARAM=REF**

$$X = \begin{bmatrix} 1 & 1 & 0 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

$$\theta = \begin{bmatrix} \mu + \delta_{<25} + \gamma_{low} + \beta_{yes} \\ \delta_{25-29} - \delta_{<25} \\ \delta_{30-39} - \delta_{<25} \\ \delta_{40-49} - \delta_{<25} \\ \gamma_{high} - \gamma_{low} \\ \beta_{yes} - \beta_{no} \end{bmatrix}$$

Conclusione

Il modello nel suo complesso è buono e conforme ai dati, come si può osservare dal test di nullità dei coefficienti e dagli odds-ratio che evidenziano una differenza tra tutti i livelli delle variabili esplicative.

Il modello migliore da usare è quello binomiale con link function "clog-log", in quanto minimizza devianza, AIC e BIC; inoltre non è preferibile utilizzare una parametrizzazione rispetto ad un'altra.

In conclusione, quindi, utilizzando questo tipo di modello, risulta efficace prevedere se una donna sposata delle Fiji fa uso di contraccettivi o meno considerando l'età, il livello di istruzione e la volontà di volere figli.